


# Model regresji wielorakiej

15 marca 2021



Rozważmy następujący model:

$$Y_t = \beta_0 + \beta_1 X_{t,1} + \beta_2 X_{t,2} + \dots + \beta_k X_{t,k} + \epsilon_t,$$

dla  $t = 1, 2, \dots, n$ , gdzie

- $X_{t,1}, X_{t,2}, \dots, X_{t,k}$  - zaobserwowane wartości zmiennych objaśniających
- $Y_t$  - zaobserwowane wartości zmiennych objaśnianych
- $\epsilon_t$  - nieznana wartość składnika losowego
- $\beta_0, \beta_1, \dots, \beta_k$  - nieznane parametry.

Model regresji wielorakiej

$$Y_t = \beta_0 + \beta_1 X_{t,1} + \beta_2 X_{t,2} + \dots + \beta_k X_{t,k} + \epsilon_t,$$

może być przedstawiony jako układ równań liniowych:

$$\begin{cases} Y_1 &= \beta_0 + \beta_1 X_{1,1} + \beta_2 X_{1,2} + \dots + \beta_k X_{1,k} + \epsilon_1 \\ Y_2 &= \beta_0 + \beta_1 X_{2,1} + \beta_2 X_{2,2} + \dots + \beta_k X_{2,k} + \epsilon_2 \\ \vdots &\vdots \qquad \qquad \qquad \vdots \\ Y_n &= \beta_0 + \beta_1 X_{n,1} + \beta_2 X_{n,2} + \dots + \beta_k X_{n,k} + \epsilon_n \end{cases}$$

lub w formie macierzowej:

# Model liniowy w formie macierzowej

$$\underbrace{\begin{bmatrix} Y_1 \\ Y_2 \\ \vdots \\ Y_n \end{bmatrix}}_{\mathbf{Y}} = \underbrace{\begin{bmatrix} 1 & X_{11} & X_{12} & \dots & X_{1k} \\ 1 & X_{21} & X_{22} & \dots & X_{2k} \\ \vdots & \vdots & \vdots & \ddots & \vdots \\ 1 & X_{n1} & X_{n2} & \dots & X_{nk} \end{bmatrix}}_{\mathbf{X}} \underbrace{\begin{bmatrix} \beta_0 \\ \beta_1 \\ \vdots \\ \beta_k \end{bmatrix}}_{\boldsymbol{\beta}} + \underbrace{\begin{bmatrix} \epsilon_1 \\ \epsilon_2 \\ \vdots \\ \epsilon_n \end{bmatrix}}_{\boldsymbol{\epsilon}}.$$

Innymi słowy, zapiszemy model wg poniższego wzoru:

$$\mathbf{Y} = \mathbf{X}\boldsymbol{\beta} + \boldsymbol{\epsilon}.$$

- **Argumenty wejściowe:** dla każdego  $t = 1, 2, \dots, n$  znamy wartości zmiennych objaśniających  $X_{t,1}, X_{t,2}, \dots, X_{t,k}$  oraz objaśnianych  $Y_t$ ;
- **Parametry zakłócające:** nie znamy wartości  $\epsilon_t$ , ale one również wpływają na wynik obserwacji;
- **Argumenty wyjściowe:** staramy się znaleźć  $\beta_0, \beta_1, \dots, \beta_k$  używając **metodę najmniejszych kwadratów**: znaleźć  $\beta_0, \beta_1, \dots, \beta_k \in \mathbb{R}$  dla których poniższe wyrażenie

$$f(\beta) = \sum_{t=1}^n (Y_t - \beta_0 - \beta_1 X_{t,1} - \beta_2 X_{t,2} - \dots - \beta_k X_{t,k})^2$$

ma wartość najmniejszą.

Podana funkcja celu

$$f(\beta) = \sum_{t=1}^n (Y_t - \beta_0 - \beta_1 X_{t,1} - \beta_2 X_{t,2} - \dots - \beta_k X_{t,k})^2$$

może być wyrażona równoważnie w formie macierzowej:

$$f(\beta) = (\mathbf{Y} - \mathbf{X} * \beta)^T * (\mathbf{Y} - \mathbf{X} * \beta).$$

### Uwaga 1

*Można odnieść wrażenie, że  $f$  jest funkcją o wartościach macierzowych. Jednak w rzeczywistości przyjmuje wartość liczbową. Co prawda  $\mathbf{Y} - \mathbf{X} * \beta$  jest macierzą rozmiaru  $n \times 1$ , stąd transpozycja  $(\mathbf{Y} - \mathbf{X} * \beta)^T$  jest macierzą rozmiaru  $1 \times n$ . Stąd  $(\mathbf{Y} - \mathbf{X} * \beta)^T * (\mathbf{Y} - \mathbf{X} * \beta)$  jest "macierzą" rozmiaru  $1 \times 1$ . Identyfikując macierz "jednokomórkową" z jej wartością,  $f$  przyjmuje wartości liczbowe.*

## Definicja 1

Niech  $\mathbf{A}$  będzie macierzą o losowych komórkach tzn. wszystkie komórki  $A_{ij}$ , ( $i = 1, \dots, p$ ,  $j = 1, 2, \dots, q$ ) są losowe

$$\mathbf{A} = \begin{bmatrix} A_{11} & A_{12} & A_{13} & \dots & A_{1q} \\ A_{21} & A_{22} & A_{23} & \dots & A_{2q} \\ \vdots & \vdots & \vdots & \ddots & \vdots \\ A_{p1} & A_{p2} & A_{p3} & \dots & A_{pq} \end{bmatrix}$$

Wtedy **wartością oczekiwaną macierzy  $\mathbf{A}$**  jest macierzą wartości oczekiwanych:

$$E(\mathbf{A}) = \begin{bmatrix} E(A_{11}) & E(A_{12}) & E(A_{13}) & \dots & E(A_{1q}) \\ E(A_{21}) & E(A_{22}) & E(A_{23}) & \dots & E(A_{2q}) \\ \vdots & \vdots & \vdots & \ddots & \vdots \\ E(A_{p1}) & E(A_{p2}) & E(A_{p3}) & \dots & E(A_{pq}) \end{bmatrix}$$

## Uwaga 2

*Na potrzeby ekonometrii, wektor  $\alpha = (\alpha_1, \alpha_2, \dots, \alpha_p)$  rozumiemy jako **odpowiednia macierz kolumnowa (nie wierszowa)**, tzn.*

$$\alpha = (\alpha_1, \alpha_2, \dots, \alpha_p) = \begin{bmatrix} \alpha_1 \\ \alpha_2 \\ \vdots \\ \alpha_p \end{bmatrix}.$$

*Możemy zapisać również  $\alpha = [\alpha_1, \alpha_2, \dots, \alpha_p]^T$ ;*



## Definicja 2

Dla wektora losowego  $\mathbf{A} = [A_1, A_2, \dots, A_p]^T$  definiujemy **macierz kowariancji**  $D^2(\mathbf{A})$  jako

$$D^2(\mathbf{A}) := \begin{bmatrix} \text{Cov}(A_1, A_1) & \text{Cov}(A_1, A_2) & \dots & \text{Cov}(A_1, A_p) \\ \text{Cov}(A_2, A_1) & \text{Cov}(A_2, A_2) & \dots & \text{Cov}(A_2, A_p) \\ \vdots & \vdots & \ddots & \vdots \\ \text{Cov}(A_p, A_1) & \text{Cov}(A_p, A_2) & \dots & \text{Cov}(A_p, A_p) \end{bmatrix}.$$

## Uwaga 3

### *Własności macierzy kowariancji*

- $D^2(\mathbf{A})$  jest **symetryczna** ponieważ  $\text{Cov}(A_i, A_j) = \text{Cov}(A_j, A_i)$  dla  $i, j = 1, 2, \dots, p$ ;
- Przekątna macierzy  $D^2(\mathbf{A})$  zawiera **wariancje**, ponieważ  $\text{Cov}(A_i, A_i) = \text{Var}(A_i)$ ;
- Jeśli  $\mathbf{A}$  jest niezdegenerowanym wektorem losowym (brak stałych składowych), wtedy  $D^2(\mathbf{A})$  jest macierzą **dodatnio określoną** tzn. dla wszystkich  $\mathbf{x} \in \mathbb{R}^p \setminus \{0\}$ ,  
 $\mathbf{x}^T * D^2(\mathbf{A}) * \mathbf{x} > 0$ ;
- $D^2(\mathbf{A})$  może być wyrażona jako

$$D^2(\mathbf{A}) = E \left( (\mathbf{A} - E(\mathbf{A})) * (\mathbf{A} - E(\mathbf{A}))^T \right).$$

## Fakt 1

Jeśli  $E(\mathbf{A}) = \mathbf{0}$  to

$$D^2(\mathbf{A}) := \begin{bmatrix} E(A_1^2) & E(A_1 A_2) & \dots & E(A_1 A_p) \\ E(A_2 A_1) & E(A_2^2) & \dots & E(A_2 A_p) \\ \vdots & \vdots & \ddots & \vdots \\ E(A_p A_1) & E(A_p A_2) & \dots & E(A_p^2) \end{bmatrix} = E(\mathbf{A}\mathbf{A}^T).$$

## Fact 1

Przypuśćmy, że zmienne losowe  $A_1, A_2, \dots, A_p$  są parami nieskorelowane (tzn.  $\text{Cov}(A_i, A_j) = 0$  dla wszystkich  $i \neq j$ ), oraz  $\text{Var}(A_i) = \sigma^2$  for  $i = 1, 2, \dots, p$ . Wtedy

$$D^2(\mathbf{A}) := \sigma^2 \mathbf{I}$$

gdzie

$$\mathbf{I} = \begin{bmatrix} 1 & 0 & \dots & 0 \\ 0 & 1 & \dots & 0 \\ \vdots & \vdots & \ddots & \vdots \\ 0 & 0 & \dots & 1 \end{bmatrix}.$$

## Założenie 1

*Założmy, że mamy więcej obserwacji niż parametrów  $k + 1 \leq n$ . Ponadto*

- Z1 Macierz  $\mathbf{X}$  zmiennych objaśniających jest deterministyczna (nie jest otrzymana w wyniku losowania), tzn. dla dowolnego  $t$ , zmienne  $[X_{t,1}, X_{t,2}, \dots, X_{t,k}]^T$  nie są losowe;*
- Z2 Rząd macierzy  $\mathbf{X}$  jest  $k + 1$ , tzn. kolumny są liniowo niezależne;*
- Z3  $E(\epsilon) = \mathbf{0}$ , tzn.  $E\epsilon_t = 0$  dla wszystkich  $t$ ;*
- Z4  $D^2(\epsilon) = E(\epsilon * \epsilon^T) = \sigma^2 \mathbf{I}$ , tzn.  $\epsilon_t$  jest ciągiem zmiennych losowych nieskorelowanych, których wariancje są takie same  $\sigma^2$ ;*
- Z5 Zmienne  $\epsilon_t$  mają rozkład normalny  $N(0, \sigma^2)$ ;*

W tym modelu  
*statystyk* zakłada Z1-Z4,  
czasami również Z5 oraz:

- wartość macierzy  
jest deterministyczna  
 $\mathbf{X}$ , tzn. uzyskał je jako  
wartość zdeterminowaną  
(w uproszczeniu nie  
jest wynikiem losowania);
- wartość wektora  $\mathbf{Y}$  jest  
losowa (w uproszczeniu  
uzyskana jest w wyniku losowania);



Statystyk nie zna

- wartości  
(deterministycznej)  
wektora  $\beta$  i próbuje  
je oszacować (jest to jego  
przedmiot zainteresowań);
- realizacji,  
czyli wylosowanej  
wartości wektora losowego  
 $\epsilon$ , nie zna nawet wariancji  
( $\sigma^2$ ), ale nie jest to jego  
przedmiot zainteresowań, jest to **parametr zakłócający**.



Funkcję celu

$$f(\beta) = \sum_{t=1}^n (Y_t - \beta_0 - \beta_1 X_{t,1} - \beta_2 X_{t,2} - \dots - \beta_k X_{t,k})^2$$

można zapisać w formie macierzowej:

$$f(\beta) = (\mathbf{Y} - \mathbf{X} * \beta)^T * (\mathbf{Y} - \mathbf{X} * \beta).$$

Funkcja celu jest **wypukła**, stąd minimalizacja  $f$  sprowadza się do przyrównanie **gradientu** wektora zerowego. Przypomnę, że

$$\text{grad}(f) = \begin{bmatrix} \frac{\partial f}{\partial \beta_0} \\ \frac{\partial f}{\partial \beta_1} \\ \vdots \\ \frac{\partial f}{\partial \beta_k} \end{bmatrix}$$



Zauważmy, że dla każdego wektora  $\mathbf{A} = [a_1, a_2, \dots, a_p]^T$  zachodzi

$$\|\mathbf{A}\|^2 = \sum_{i=1}^p a_i^2 = \mathbf{A}^T * \mathbf{A}.$$

Można więc przekształcić funkcję celu:

$$\begin{aligned} f(\beta) &= (\mathbf{Y} - \mathbf{X} * \beta)^T * (\mathbf{Y} - \mathbf{X} * \beta) \\ &= (\mathbf{Y}^T - (\mathbf{X} * \beta)^T) * (\mathbf{Y} - \mathbf{X} * \beta) \\ &= (\mathbf{Y}^T - \beta^T * \mathbf{X}^T) * (\mathbf{Y} - \mathbf{X} * \beta) \\ &= \mathbf{Y}^T * \mathbf{Y} - \mathbf{Y}^T * \mathbf{X} * \beta - \beta^T * \mathbf{X}^T * \mathbf{Y} + \beta^T * \mathbf{X}^T * \mathbf{X} * \beta \\ &= \|\mathbf{Y}\|^2 - \mathbf{Y}^T * \mathbf{X} * \beta - (\mathbf{Y}^T * \mathbf{X} * \beta)^T + \|\mathbf{X} * \beta\|^2. \end{aligned}$$

Zauważmy, że  $\mathbf{Y}^T * \mathbf{X} * \beta$  jest macierzą jeden na jeden. Ten fakt wynika z tego, że  $\mathbf{Y}$  jest macierzą rozmiaru  $n \times 1$ , stąd  $\mathbf{Y}^T$  ma rozmiar  $1 \times n$ . Dalej  $\mathbf{X}$  jest macierzą  $n \times k$ , stąd  $\mathbf{Y}^T * \mathbf{X}$  jest macierzą  $1 \times k$ . Zatem ponieważ  $\beta$  ma rozmiar  $k \times 1$ , stąd  $\mathbf{Y}^T * \mathbf{X} * \beta$  jest rozmiaru  $1 \times 1$  - *macierz jednokomórkowa*:

$$\left( \underbrace{\mathbf{Y}^T}_{1 \times n} * \underbrace{\mathbf{X}}_{n \times k} * \underbrace{\beta}_{k \times 1} \right) \Rightarrow \left( \underbrace{\mathbf{Y}^T * \mathbf{X} * \beta}_{\text{jest } 1 \times 1} \right).$$

Transpozycja macierzy  $1 \times 1$  jest również macierzą  $1 \times 1$  i ma tą samą wartość

$$\left( \underbrace{\mathbf{Y}^T * \mathbf{X} * \beta}_{\text{jest } 1 \times 1} \right)^T = \left( \underbrace{\mathbf{Y}^T * \mathbf{X} * \beta}_{\text{jest } 1 \times 1} \right).$$

Stąd otrzymujemy

$$\begin{aligned} f(\beta) &= ||\mathbf{Y}||^2 - \underbrace{\left( \mathbf{Y}^T * \mathbf{X} * \beta + \left( \mathbf{Y}^T * \mathbf{X} * \beta \right)^T \right)}_{\text{Oba składniki są równe}} \\ &\quad + ||\mathbf{X} * \beta||^2 \\ &= ||\mathbf{Y}||^2 - 2\mathbf{Y}^T * \mathbf{X} * \beta + ||\mathbf{X} * \beta||^2 \end{aligned}$$

Zatem

$$\begin{aligned} \text{grad}(f) &= \text{grad} \left( \|\mathbf{Y}\|^2 - 2\mathbf{Y}^T * \mathbf{X} * \beta + \|\mathbf{X} * \beta\|^2 \right) \\ &= \text{grad}(\|\mathbf{Y}\|^2) - \text{grad} \left( 2\mathbf{Y}^T * \mathbf{X} * \beta \right) + \text{grad}(\|\mathbf{X} * \beta\|^2) \\ &= \underbrace{-2\mathbf{X}^T * \mathbf{Y} + 2\mathbf{X}^T * \mathbf{X} * \beta}_{\text{Uwierz na słowo}}. \end{aligned}$$

Teraz otrzymujemy

$$\begin{aligned} (\text{grad}(f) = \mathbf{0}) &\Leftrightarrow (-2\mathbf{X}^T * \mathbf{Y} + 2\mathbf{X}^T * \mathbf{X} * \beta = \mathbf{0} \mid :2) \\ &\Leftrightarrow -\mathbf{X}^T * \mathbf{Y} + \mathbf{X}^T * \mathbf{X} * \beta = \mathbf{0} \\ &\Leftrightarrow (\mathbf{X}^T * \mathbf{X}) * \beta = \mathbf{X}^T * \mathbf{Y}. \end{aligned}$$

Mamy więc

$$\underbrace{(\mathbf{X}^T * \mathbf{X})} * \beta = \mathbf{X}^T * \mathbf{Y}$$

Z założenia Z2 macierz jest nieosobliwa

Zatem otrzymujemy jedyny estymator metody **najmniejszych kwadratów**

$$\hat{\beta} = (\mathbf{X}^T * \mathbf{X})^{-1} * \mathbf{X}^T * \mathbf{Y}.$$

## Twierdzenie 1 (Gausa-Markova)

*Estymator wyrażony wzorem*

$$\hat{\beta} = (\mathbf{X}^T * \mathbf{X})^{-1} * \mathbf{X}^T * \mathbf{Y}.$$

*jest jedynym estymatorem otrzymanym metodą **najmniejszych kwadratów**. Ponadto*

- *jest liniowy, tzn. jest przekształceniem liniowym wektora losowego  $\mathbf{Y}$ ;*
- *jest nieobciążony  $E(\hat{\beta}) = \beta$ ;*
- *jest zgodny tzn. jeśli estymator  $\hat{\beta}^n$  bazuje na  $n$  obserwacjach*

$$\forall \delta > 0 P(|\hat{\beta}^n - \beta| > \delta) \rightarrow 0 \text{ o ile } n \rightarrow \infty;$$

- *jest efektywnym: tzn. ma najmniejszą wariancję ze wszystkich estymatorów liniowych i nieobciążonych.*

$\hat{\beta}$  jest nieobciążony tzn.  $E(\hat{\beta}) = \beta$

Model jest postaci

$$\mathbf{Y} = \mathbf{X}\beta + \epsilon,$$

gdzie  $\mathbf{X}$  jest macierzą deterministyczną spełniającą (Z2) oraz  $E(\epsilon) = \mathbf{0}$  (Z3). Stąd

$$\begin{aligned} E(\hat{\beta}) &= E(\mathbf{X}^T * \mathbf{X})^{-1} * \mathbf{X}^T * \mathbf{Y} \\ &= (\mathbf{X}^T * \mathbf{X})^{-1} * \mathbf{X}^T * E(\mathbf{Y}) \\ &= (\mathbf{X}^T * \mathbf{X})^{-1} * \mathbf{X}^T * E(\mathbf{X}\beta + \epsilon) \\ &= (\mathbf{X}^T * \mathbf{X})^{-1} * \mathbf{X}^T (\mathbf{X}\beta + \mathbf{0}) \\ &= (\mathbf{X}^T * \mathbf{X})^{-1} * (\mathbf{X}^T \mathbf{X}) \beta \\ &= \mathbf{I}\beta = \beta \end{aligned}$$

## Twierdzenie 2

*Macierz kowariancji  $\hat{\beta}$  spełnia*

$$D^2(\hat{\beta}) = \sigma^2(\mathbf{X}^T \mathbf{X})^{-1}.$$



Ponieważ  $\hat{\beta}$  jest estymatorem nieobciążonym, stąd  $E(\hat{\beta}) = \beta$  oraz

$$D^2(\hat{\beta}) := E(\hat{\beta} - E(\hat{\beta}))(\hat{\beta} - E(\hat{\beta}))^T = E(\hat{\beta} - \beta) * (\hat{\beta} - \beta)^T.$$

Ponadto

$$\begin{aligned}\mathbf{Y} = \mathbf{X}\beta + \epsilon &\Rightarrow \mathbf{X}^T * \mathbf{Y} = \mathbf{X}^T * \mathbf{X} * \beta + \mathbf{X}^T * \epsilon \\ &\Leftrightarrow \mathbf{X}^T(\mathbf{Y} - \epsilon) = (\mathbf{X}^T * \mathbf{X}) * \beta \\ &\Leftrightarrow \beta = (\mathbf{X}^T * \mathbf{X})^{-1} * \mathbf{X}^T(\mathbf{Y} - \epsilon).\end{aligned}$$

Stąd

$$\begin{aligned}\hat{\beta} - \beta &= (\mathbf{X}^T * \mathbf{X})^{-1} * \mathbf{X}^T \mathbf{Y} - (\mathbf{X}^T * \mathbf{X})^{-1} * \mathbf{X}^T (\mathbf{Y} - \epsilon) \\ &= (\mathbf{X}^T * \mathbf{X})^{-1} * \mathbf{X}^T * \epsilon.\end{aligned}$$

## Dowód twierdzenia 2 - ciąg dalszy

Stąd

$$\begin{aligned} D^2(\hat{\beta}) &= E \left( \left( (\mathbf{X}^T * \mathbf{X})^{-1} * \mathbf{X}^T * \epsilon \right) * \left( (\mathbf{X}^T * \mathbf{X})^{-1} * \mathbf{X}^T * \epsilon \right)^T \right) \\ &= E \left( \left( (\mathbf{X}^T * \mathbf{X})^{-1} * \mathbf{X}^T * \epsilon \right) * \left( \epsilon^T * \mathbf{X} * (\mathbf{X}^T * \mathbf{X})^{-1} \right) \right) \\ &= E \left( \underbrace{(\mathbf{X}^T * \mathbf{X})^{-1} * \mathbf{X}^T}_{\text{m. deterministyczna}} * (\epsilon * \epsilon^T) * \underbrace{\mathbf{X} * (\mathbf{X}^T * \mathbf{X})^{-1}}_{\text{m. deterministyczna}} \right) \\ &= (\mathbf{X}^T * \mathbf{X})^{-1} * \mathbf{X}^T * \underbrace{E(\epsilon * \epsilon^T)}_{\text{By Z4 } E(\epsilon * \epsilon^T) = \sigma^2 \mathbf{I}} * \mathbf{X} * (\mathbf{X}^T * \mathbf{X})^{-1} \\ &= (\mathbf{X}^T * \mathbf{X})^{-1} * \mathbf{X}^T * \sigma^2 \mathbf{I} * \mathbf{X} * (\mathbf{X}^T * \mathbf{X})^{-1} \\ &= \sigma^2 \underbrace{(\mathbf{X}^T * \mathbf{X})^{-1} * (\mathbf{X}^T * \mathbf{X})}_{\text{m. odwrotne}} * (\mathbf{X}^T * \mathbf{X})^{-1} = \sigma^2 (\mathbf{X}^T * \mathbf{X})^{-1}. \end{aligned}$$

## Przykład 1 (Ekonometria, Przykład 2.1. Gruszczyński i Podgórska, Szkoła Główna Handlowa w Warszawie)

*Na podstawie danych umieszczonych na następnym slajdzie dopasujemy model między poziomem (stopą) inflacji a poziomem (stopą) bezrobocia. Znajdziemy następnie model postaci:*



$$Y_t = \beta_0 + \beta_1 X_{t,1} + \beta_2 X_{t,2} + \epsilon_t$$

*gdzie  $Y_t$ -poziom inflacji,  $X_{t,1}$  poziom bezrobocia i  $X_{t,2}$  oczekiwany poziom inflacji na lata o indeksie  $t = 1, 2, \dots, 15$ .*

| inflacja<br>(objaśniana) | bezrobocie<br>(objaśniająca) | oczekiwana inflacja<br>(objaśniająca) |
|--------------------------|------------------------------|---------------------------------------|
| 5.92                     | 4.9                          | 4.78                                  |
| 4.30                     | 5.9                          | 3.84                                  |
| 3.30                     | 5.6                          | 3.13                                  |
| 6.23                     | 4.9                          | 3.44                                  |
| 10.97                    | 5.6                          | 6.84                                  |
| 9.14                     | 8.5                          | 9.47                                  |
| 5.77                     | 7.7                          | 6.51                                  |
| 6.45                     | 7.1                          | 5.92                                  |
| 7.60                     | 6.1                          | 6.08                                  |
| 11.47                    | 5.8                          | 8.09                                  |

## Przykład - rozwiązanie

$$\mathbf{X} = \begin{bmatrix} 1 & 4.9 & 4.78 \\ 1 & 5.9 & 3.84 \\ 1 & 5.6 & 3.13 \\ 1 & 4.9 & 3.44 \\ 1 & 5.6 & 6.84 \\ 1 & 8.5 & 9.47 \\ 1 & 7.7 & 6.51 \\ 1 & 7.1 & 5.92 \\ 1 & 6.1 & 6.08 \\ 1 & 5.8 & 8.09 \end{bmatrix} \quad \mathbf{Y} = \begin{bmatrix} 5.92 \\ 4.30 \\ 3.30 \\ 6.23 \\ 10.97 \\ 9.14 \\ 5.77 \\ 6.45 \\ 7.60 \\ 11.47 \end{bmatrix}$$

# Przykład - rozwiązanie

$$\mathbf{X}^T * \mathbf{X} =$$

$$\begin{bmatrix} 1 & 1 & 1 & 1 & 1 & 1 & 1 & 1 & 1 & 1 \\ 4.9 & 5.9 & 5.6 & 4.9 & 5.6 & 8.5 & 7.7 & 7.1 & 6.1 & 5.8 \\ 4.78 & 3.84 & 3.13 & 3.44 & 6.84 & 9.47 & 6.51 & 5.92 & 6.08 & 8.09 \end{bmatrix} \begin{bmatrix} 1 & 4.9 & 4.78 \\ 1 & 5.9 & 3.84 \\ 1 & 5.6 & 3.13 \\ 1 & 4.9 & 3.44 \\ 1 & 5.6 & 6.84 \\ 1 & 8.5 & 9.47 \\ 1 & 7.7 & 6.51 \\ 1 & 7.1 & 5.92 \\ 1 & 6.1 & 6.08 \\ 1 & 5.8 & 8.09 \end{bmatrix} = \begin{bmatrix} 10.000 & 62.100 & 58.100 \\ 62.100 & 398.350 & 375.430 \\ 58.100 & 375.430 & 375.532 \end{bmatrix}$$

Z dokładnością do błędu zaokrągleń mamy:

$$(\mathbf{X}^T \mathbf{X})^{-1} = \begin{bmatrix} 3.219132 & -0.561521 & 0.063325 \\ -0.561521 & 0.141384 & -0.054471 \\ 0.063325 & -0.054471 & 0.047322 \end{bmatrix}$$



# Przykład - rozwiązanie

$$\mathbf{X}^T \mathbf{Y} = \begin{bmatrix} 1 & 1 & 1 & 1 & 1 & 1 & 1 & 1 & 1 & 1 \\ 4.9 & 5.9 & 5.6 & 4.9 & 5.6 & 8.5 & 7.7 & 7.1 & 6.1 & 5.8 \\ 4.78 & 3.84 & 3.13 & 3.44 & 6.84 & 9.47 & 6.51 & 5.92 & 6.08 & 8.09 \end{bmatrix} \begin{bmatrix} 5.92 \\ 4.30 \\ 3.30 \\ 6.23 \\ 10.97 \\ 9.14 \\ 5.77 \\ 6.45 \\ 7.60 \\ 11.47 \end{bmatrix}$$
$$= \begin{bmatrix} 71.150 \\ 445.617 \\ 452.907 \end{bmatrix}$$

# Przykład - rozwiązanie

Następnie podstawiamy do wzoru

$$\hat{\beta} = (\mathbf{X}^T \mathbf{X})^{-1} \mathbf{X}^T \mathbf{Y} =$$
$$= \begin{bmatrix} 3.219132 & -0.561521 & 0.063325 \\ -0.561521 & 0.141384 & -0.054471 \\ 0.063325 & -0.054471 & 0.047322 \end{bmatrix} \begin{bmatrix} 71.150 \\ 445.617 \\ 452.907 \end{bmatrix} = \begin{bmatrix} 7.4979 \\ -1.6192 \\ 1.6648 \end{bmatrix}$$

Daje to następujące oszacowanie modelu:

$$\underbrace{Y_t}_{\text{inflacja}} = 7.4979 - 1.6192 * \underbrace{X_{t,2}}_{\text{bezrobocie}} + 1.6648 * \underbrace{X_{t,2}}_{\text{oczekiwana inflacja}} + \epsilon_t$$